Aprendizaje asistido por IA y reversión de la degradación de habilidades a largo plazo

Presentación final — Modalidad A

Artificial Intelligence and Economic Modeling

William Grados

6 de noviembre de 2026

https://github.com/wbgradost/ai-project

¿Puede la IA mejorar las habilidades a largo plazo mientras reduce el esfuerzo humano?

Resultado central, con su condición

En el modelo de dos estados, con $b, \lambda_0, \kappa, \mu > 0$ y $\eta \geq 0$, la asistencia aumenta inicialmente la proporción estacionaria de habilidad alta si y solo si $\eta b > 1$, aunque desplaza esfuerzo humano.

$$\lambda(e, a) = \lambda_0 + \kappa e(1 + \eta a).$$

b es el esfuerzo sin IA; η mide la complementariedad entre IA y esfuerzo en el aprendizaje. La mejora es acotada: cuando desaparece el esfuerzo, solo permanece el aprendizaje basal.

Del desplazamiento del esfuerzo a nuestra extensión

Aouad, Lykouris y Zhong (2026), Proposición 3.5: si el aprendizaje depende solo del esfuerzo, una mayor asistencia desplaza débilmente hacia abajo la distribución estacionaria de habilidades.

- Conservamos el problema miope del trabajador y su regla de desempate.
- Modificamos únicamente la tecnología de aprendizaje: la IA puede elevar el rendimiento del esfuerzo que permanece.
- Caracterizamos exactamente los umbrales y las comparaciones en dos estados.

La contribución describe la distribución de habilidades; no establece un ordenamiento de bienestar ni una política óptima de asistencia.

Aouad, Lykouris y Zhong, *Human-AI Productivity Paradoxes*, arXiv:2605.11350v1, Prop. 3.5. Extensión del manuscrito propio fijado en 7cc3a740.

Lema 1: la decisión del trabajador no cambia

Para habilidad fija $s \geq 0$ y asistencia $a \geq 0$,

$$\max_{e \geq 0} \; p(s + e + a) - \gamma e, \qquad \gamma > 0.$$

p es continuamente diferenciable, no decreciente y cóncava; $\limsup_{x \to \infty} p(x)/x < \gamma$ garantiza máximos finitos.

$$x^* = \max \arg\max_{x \geq 0} \{p(x) - \gamma x\}, \qquad e^*(s, a) = \max\{x^* - s - a, 0\}.$$

Se elige el **mayor maximizador** en caso de empate.

$$e > 0 : \; p'(s + e + a) = \gamma; \qquad e = 0 : \; p'(s + a) \leq \gamma.$$

El aprendizaje no entra en el objetivo miope: su modificación conserva la condición de primer orden y el desplazamiento del esfuerzo.

Lema 2: transiciones y distribución estacionaria

$$0 \le s_L < s_H, \quad b = x^* - s_L > 0, \qquad \boxed{e_L^*(a) = \max\{b - a, 0\}.}$$

Para cada asistencia fija $a \ge 0$, la cadena de Markov de tiempo continuo tiene

$$Q(a) = \begin{pmatrix} -\lambda_L(a) & \lambda_L(a) \\ \mu & -\mu \end{pmatrix}, \quad \lambda_L(a) = \lambda_0 + \kappa \max\{b - a, 0\}(1 + \eta a).$$

Suponemos $\lambda_0, \kappa, \mu > 0$ y $\eta \ge 0$ en todo el análisis. El balance y la normalización implican una distribución estacionaria única:

$$(1 - \pi_H)\lambda_L = \pi_H \mu \quad \Longrightarrow \quad \boxed{\pi_H(a) = \frac{\lambda_L(a)}{\lambda_L(a) + \mu}.}$$

Las tasas positivas garantizan irreducibilidad. El esfuerzo en H no afecta las transiciones porque no existe un estado superior.

En la región con esfuerzo positivo, $0 \leq a < b$, definimos

$$L(a) = \lambda_0 + \kappa(b-a)(1+\eta a) = \lambda_L(a).$$

Su efecto marginal se descompone en

$$L'(a) = \kappa \left[\underbrace{\eta(b-a)}_{\text{rendimiento del esfuerzo restante}} - \underbrace{(1+\eta a)}_{\text{esfuerzo desplazado}} \right] = \kappa[\eta(b-2a)-1].$$

Mecanismo económico

La IA reduce el esfuerzo, pero puede aumentar su productividad para aprender. El efecto neto es positivo solamente si la complementariedad supera el desplazamiento: $\eta(b-2a) > 1$.

Para $a \geq b$, $e_L^* = 0$ y $\lambda_L = \lambda_0$: la complementariedad ya no opera.

Proposición 1: forma global y máximo estacionario

Bajo los supuestos de los dos lemas anteriores:

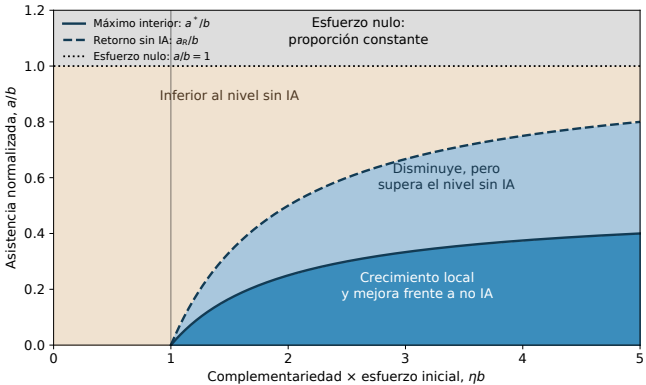
- Si $\eta b \leq 1$, π_H disminuye estrictamente en $[0, b]$ y después es constante. Su máximo global único está en $a = 0$.
- Si $\eta b > 1$, definimos

$$a^* = \frac{b - 1/\eta}{2}, \qquad a_R = b - \frac{1}{\eta} = 2a^*.$$

  Entonces $0 < a^* < a_R < b$: π_H aumenta estrictamente en $[0, a^*]$, disminuye estrictamente en $[a^*, b]$ y es constante en $[b, \infty)$.
- El máximo global único es a^* en el régimen fuerte. La mejora frente a no usar IA ocurre exactamente cuando $0 < a < a_R$.

En la frontera $\eta b = 1$, $\pi_H'(0+) = 0$, pero no existe un intervalo creciente. Para $a \geq b$, $\pi_H = \lambda_0/(\lambda_0 + \mu) < \pi_H(0)$.

Tres umbrales que responden preguntas distintas



Si $\eta b > 1$:

Máximo: $a^* = (b - 1/\eta)/2$.

Retorno sin IA: $a_R = 2a^*$, con $\pi_H(a_R) = \pi_H(0)$.

Esfuerzo nulo: $b > a_R$.

En (a^*, a_R) la habilidad disminuye, pero todavía supera el nivel sin IA.

Evaluación de fórmulas cerradas. Ejes normalizados: a/b y ηb. La región de crecimiento local difiere de la región de mejora frente a no usar IA.

Demostración: signos, curvatura y frontera del esfuerzo

Para $0 \le a < b$ (derivada derecha en cero),

$$\boxed{\pi'_H(a) = \frac{\mu\kappa[\eta(b-2a)-1]}{[L(a)+\mu]^2}.}$$

$\mu, \kappa > 0$ y el denominador positivo hacen que el signo dependa exclusivamente de $\eta(b-2a)-1$. Su raíz es positiva si y solo si $\eta b > 1$.

Si $f(a) = (b-a)(1+\eta a)$, en $(0, b)$:

$$\pi''_H = -\frac{2\mu\kappa\eta}{(L+\mu)^2} - \frac{2\mu\kappa^2[f'(a)]^2}{(L+\mu)^3} < 0.$$

Si $\eta = 0$, $f' = -1$ conserva la desigualdad estricta. En b hay continuidad, pero no diferenciabilidad:

$$\pi'_H(b-) = -\frac{\mu\kappa(1+\eta b)}{(\lambda_0+\mu)^2} < 0, \qquad \pi'_H(b+) = 0.$$

La rama activa es estrictamente cóncava; la curva completa no es cóncava.

Proposición 2: comparar dos niveles de asistencia

Para $0 \leq a_\ell < a_h < b$, bajo los mismos supuestos,

$$\pi_H(a_h) - \pi_H(a_\ell) = \frac{\mu\kappa(a_h - a_\ell)[\eta(b - a_h - a_\ell) - 1]}{[L(a_h) + \mu][L(a_\ell) + \mu]}.$$

$$\boxed{\pi_H(a_h) > \pi_H(a_\ell) \iff \eta(b - a_h - a_\ell) > 1.}$$

- Igualdad si y solo si $\eta(b - a_h - a_\ell) = 1$; disminución si es menor que uno.
- Si $a_\ell < b \leq a_h$, la habilidad disminuye estrictamente. Si $b \leq a_\ell < a_h$, las proporciones son iguales.
- En dos estados, ordenar π_H equivale a ordenar la habilidad media y la dominancia estocástica de primer orden.

La fórmula activa también es válida en $a_h = b$.

Demostración: una factorización para tres comparaciones

Restar las fracciones estacionarias elimina el producto de las tasas:

$$\pi_H(v) - \pi_H(u) = \frac{\mu[\lambda_L(v) - \lambda_L(u)]}{[\lambda_L(v) + \mu][\lambda_L(u) + \mu]}.$$

Para $0 \le u < v \le b$, expandir y factorizar da

$$L(v) - L(u) = \kappa(v - u)[\eta(b - u - v) - 1].$$

Los demás factores son positivos. Así obtenemos condiciones necesarias y suficientes, sin asumir el signo que se pretende demostrar.

Comparación	Condición de mejora	Régimen fuerte
Marginal en a	$\eta(b - 2a) > 1$	$a < a^*$
Frente a no usar IA	$a > 0$, $\eta(b - a) > 1$	$0 < a < a_R$
Entre u y v	$\eta(b - u - v) > 1$	$u + v < a_R$

Las dos últimas equivalencias se refieren a la región activa; fuera de ella se aplica la saturación.

Ejemplo ilustrativo: $p(x) = 4\log(1+x)$, $\gamma = 1$, $s_L = 1$, $s_H = 3$.

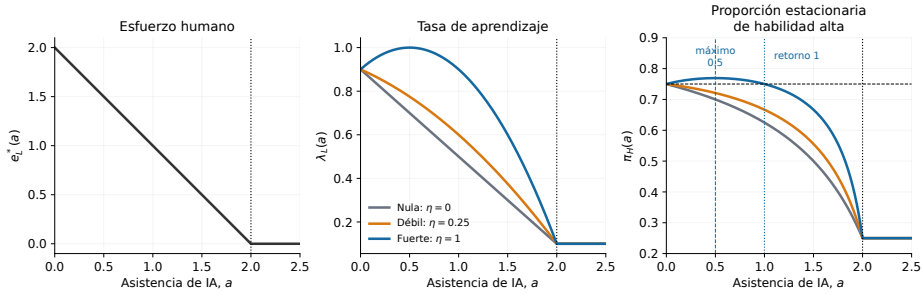
$$x^* = 3, \quad b = 2, \qquad \lambda_0 = 0.1, \quad \kappa = 0.4, \quad \mu = 0.3.$$

Complementariedad	η	ηb	Predicción analítica
Nula	0	0	disminución
Débil	0.25	0.5	disminución
Fuerte	1	2	aumento y posterior disminución

- Las curvas evalúan fórmulas cerradas: ilustran la estática comparativa.
- Las trayectorias aleatorias contrastan ocupaciones con la predicción dinámica.

Las tasas comparten una unidad temporal; s, e, a tienen la misma unidad y η su inversa.
No son parámetros estimados con datos.

Simulaciones 2/5: menos esfuerzo y una mejora acotada

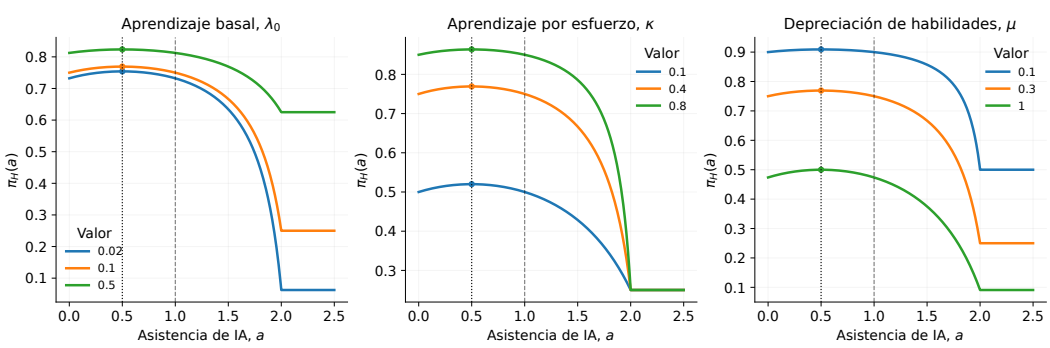


Asistencia	0	$a^* = 0.5$	$a_R = 1$	$b = 2$
Esfuerzo	2	1.5	1	0
Aprendizaje	0.9	1.0	0.9	0.1
Habilidad alta	75.00 %	76.92 %	75.00 %	25.00 %

El máximo gana 1.9231 puntos porcentuales con 25 % menos esfuerzo. Solo la complementariedad fuerte genera una región creciente.

Evaluaciones numéricas de las fórmulas cerradas; no son simulaciones estocásticas.

Simulaciones 3/5: sensibilidad y robustez del mecanismo



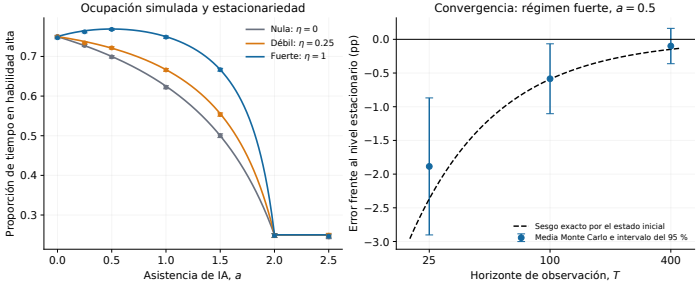
Los umbrales dependen solo de (b, η); λ_0, κ, μ modifican los niveles y la magnitud de la ganancia, sin mover a^*, a_R, b.

Multiplicar las tres tasas por $c > 0$ conserva π_H y acelera la convergencia por c. La ganancia no necesariamente aumenta con κ o con μ.

Barridos de parámetros existentes y verificación de invariancia por escala. Las conclusiones analíticas corresponden al Corolario 1.

Con $r = \lambda_L + \mu$ y estado inicial L, el Lema 2 predice

$$\Pr(S_t = H) = \pi_H(1 - e^{-rt}), \quad E[\widehat{A}_T] = \pi_H\left[1 - \frac{1 - e^{-rT}}{rT}\right], \quad \widehat{A}_T = \frac{1}{T}\int_0^T 1_{\{S_t = H\}}\, dt.$$



384 trayectorias independientes por celda; 21 celdas; $T = 25, 100, 400$; semilla 20261104. Esperas exponenciales exactas, sin discretización ni descarte inicial; se incluye el último intervalo parcial.

Se mide tiempo de ocupación, no número de visitas: la cadena de saltos de dos estados alterna.

Simulaciones 5/5: precisión, comprobaciones y límites

$$\overline{A}_T - \pi_H = \underbrace{\overline{A}_T - E[\widehat{A}_T]}_{\text{error Monte Carlo}} + \underbrace{E[\widehat{A}_T] - \pi_H}_{\text{sesgo por el estado inicial}} .$$

Diagnóstico máximo	Resultado
Diferencia frente al nivel estacionario, $T = 400$	0.5223 pp
Diferencia frente a la media exacta finita, $T = 400$	0.3661 pp
Sesgo exacto por estado inicial, $T = 400$	0.2083 pp
Error estandarizado, **todos los horizontes**	1.8486

- Intervalos nominales del 95 % con errores estándar entre trayectorias; umbral diagnóstico de seis errores estándar exactos.
- 28 identidades simbólicas, 300 casos paramétricos y 32 comprobaciones independientes del esfuerzo; se incluyen igualdades y fronteras.
- La coincidencia numérica respalda la implementación; no sustituye la demostración ni identifica efectos causales en datos.

Resultados guardados en code/output/; ejecución reproducible: python code/verify.py.

Corolario 1: qué determina los umbrales y las ganancias

En el régimen fuerte, $\eta_c = 1/b$ y

$$\frac{\partial a^*}{\partial b} = \frac{1}{2}, \quad \frac{\partial a_R}{\partial b} = 1, \qquad \frac{\partial a^*}{\partial \eta} = \frac{1}{2\eta^2}, \quad \frac{\partial a_R}{\partial \eta} = \frac{1}{\eta^2}.$$

Un mayor esfuerzo inicial b reduce la complementariedad crítica; una mayor η amplía la región de mejora. Las otras tasas no mueven los umbrales.

La ganancia máxima de aprendizaje es

$$\Delta L = L(a^*) - L(0) = \frac{\kappa(\eta b - 1)^2}{4\eta}, \qquad \pi_H(a^*) - \pi_H(0) = \frac{\mu\, \Delta L}{[L(a^*) + \mu][L(0) + \mu]}.$$

Cerca de $\eta b = 1$, la mejora es de segundo orden. El denominador explica por qué mayor aprendizaje adicional no se traduce proporcionalmente en habilidad.

Proposición 2: para $0 \le u < v \le b$,

$$\pi_H(v) > \pi_H(u) \iff \eta(b - u - v) > 1.$$

Declaración del archivo `Algebra.lean`:

```
theorem active_pair_increase_iff (p : Parameters) {u v : ℝ}
    (hu : 0 ≤ u) (huv : u < v) (hv : v ≤ p.b) :
    stationaryShare p u < stationaryShare p v ↔ p.eta * (p.b - u - v) > 1 := by
```

`Parameters` exige $b, \lambda_0, \kappa, \mu > 0$ y $\eta \ge 0$. `stationaryShare` es exactamente $[\lambda_0 + \kappa\,\mathrm{máx}\{b - a, 0\}(1 + \eta a)]/[\lambda_L(a) + \mu]$.

La declaración incluye $v = b$, como el manuscrito. Las hipótesis son los supuestos económicos y el dominio; ninguna incorpora la conclusión.

Demostración de `active_pair_increase_iff`:

```
rw [share_order_iff p hu (le_trans hu huv.le), ← sub_pos,
  effectiveEffort_active_difference p (le_trans huv.le hv) hv,
  mul_pos_iff_of_pos_left (sub_pos.mpr huv), sub_pos]
```

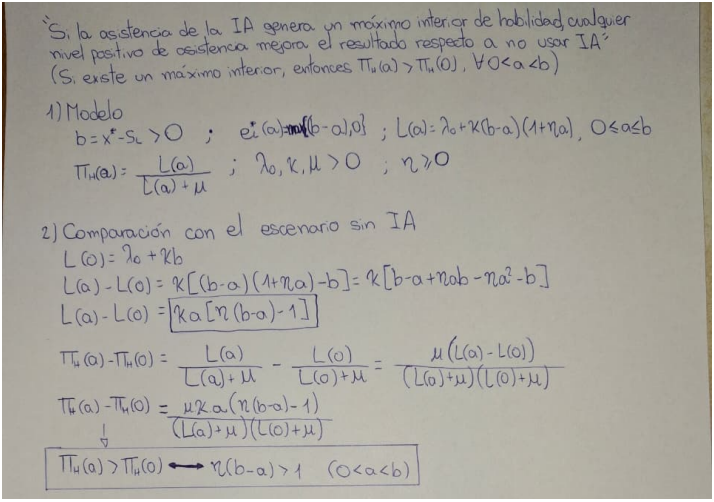
1. `share_order_iff`: los denominadores positivos transfieren el orden a $(b-a)^+(1+\eta a)$.
2. `effectiveEffort_active_difference`: factoriza la diferencia como $(v-u)[\eta(b-u-v)-1]$.
3. $v-u>0$ permite cancelar ese factor y obtener la equivalencia exacta.

Verificado: necesidad y suficiencia de la condición de comparación de la fórmula estacionaria; el módulo también prueba igualdad, disminución, saturación y la equivalencia con dominancia en dos estados.

Alcance: esta evidencia no certifica todavía los cinco resultados completos, la construcción probabilística de la cadena ni las simulaciones.

Código y comprobación auténtica conservados en lean/Grados26Learning/. No se utiliza sorry, admit ni axiomas adicionales.

Comprobación manuscrita: cuestionar una generalización



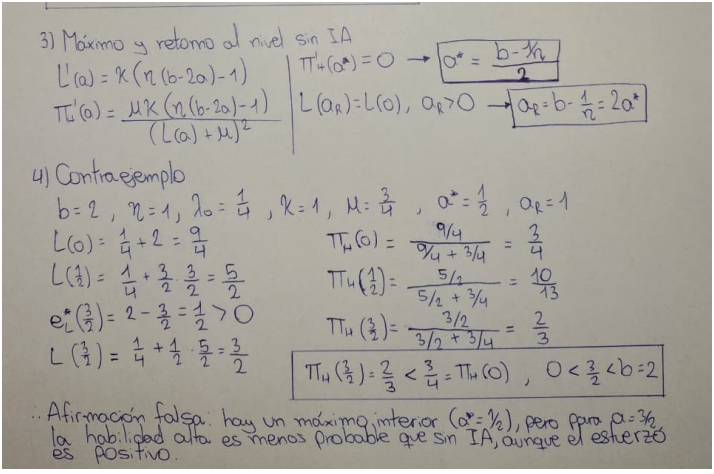
Afirmación contrastada: «Si existe un máximo interior, cualquier asistencia positiva mejora frente a no usar IA».

Operación independiente: restar las fracciones estacionarias y factorizar $L(a) - L(0)$.

El signo correcto depende de $\eta(b-a) - 1$, además de $a > 0$.

Fotografía original de la derivación del autor: hand/derivacion_manuscrita.jpeg. Se muestra un recorte del mismo archivo, sin reconstruir la escritura.

Comprobación manuscrita: afirmación refutada



La hoja usa un ejemplo independiente: $b = 2$, $\eta = 1$, $\lambda_0 = 1/4$, $\kappa = 1$, $\mu = 3/4$.

$$a^* = 1/2, \qquad a_R = 1.$$

A pesar del máximo interior,

$$\pi_H(3/2) = 2/3 < 3/4 = \pi_H(0).$$

Conclusión: la afirmación general es falsa. El resultado correcto exige $0 < a < a_R$; $a < b$ no basta.

Continuación de la fotografía original. Sus tasas son distintas del escenario de simulación; el contraejemplo no necesita parámetros estimados.

Preguntas para la discusión

1. ¿Es convincente la complementariedad en el aprendizaje cuando el trabajador sigue siendo miope, o conviene que el siguiente modelo incorpore decisiones de esfuerzo con visión de futuro?
2. ¿Qué resultado observable permitiría distinguir η del aprendizaje basal λ_0 y de la eficacia del esfuerzo κ?
3. ¿Qué condiciones sobre transiciones adicionales permitirían conservar la reversión en tres estados, y qué resultado de bienestar debería acompañarla?

El resultado demostrado pertenece a dos estados y a asistencia fija. La extensión a más estados y el diseño de políticas quedan abiertos.